

Detecção de Anomalias em Robôs Industriais

1st Andre

Centro de Informática - UFPE
Recife, Brazil
@cin.ufpe.br

2nd Bianca

Centro de Informática - UFPE
Recife, Brazil
@cin.ufpe.br

3rd Caio

Centro de Informática - UFPE
Recife, Brazil
@cin.ufpe.br

4rd Rodrigo

Centro de Informática - UFPE
Recife, Brazil
@cin.ufpe.br

Abstract—The growing adoption of industrial robots in manufacturing and automation environments has increased the demand for reliable monitoring and early fault detection systems. In industrial contexts, operational anomalies can result in physical damage to equipment, production downtime, risks to human safety, and high corrective maintenance costs. Regarding existing solutions, the literature ranges from analytical dynamic model based approaches, which compare actual behavior with physical simulations but rely on precise parameterization, to classical statistical methods and state estimation filters. More recently, data driven techniques based on Machine Learning and Deep Learning have gained prominence for their ability to model complex non linearities without the need for explicit physical modeling. This work investigates the problem of anomaly detection in industrial robots using time series data from Inertial Measurement Units (IMU), which capture information on acceleration, rotation, and magnetic fields across spatial axes. Different types of mechanical faults are considered, including collisions, mechanical overload, and external disturbances, which distinctly affect the robot's physical dynamics.

I. INTRODUÇÃO

A motivação para este estudo decorre da crescente adoção de robôs industriais em operações críticas, onde a execução de tarefas repetitivas em proximidade com operadores exige monitoramento constante. Neste contexto, a identificação automática de anomalias é essencial para detectar falhas mecânicas e interferências externas, garantindo a integridade do equipamento e a segurança do processo.

A análise baseia-se em dados de sensores inerciais (IMU), capazes de capturar a dinâmica do manipulador. O acelerômetro monitora vibrações e impactos abruptos (indicativos de colisões), enquanto o giroscópio registra a velocidade angular, permitindo identificar oscilações ou atrasos causados por cargas excessivas. O magnetômetro, mede a orientação do sistema em relação ao campo magnético terrestre, apresentando variações mais lentas e sendo sensível a interferências magnéticas inesperadas. Como o robô opera em ciclos sequenciais, os sinais normais apresentam periodicidade bem definida; desvios nesse padrão, como alterações de forma de onda ou picos de energia, constituem as assinaturas principais de condições anômalas.

O conjunto de dados utilizado provém de experimentos públicos (IEEE PerCom 2023) realizados com um braço

robótico UR3e em ambiente controlado. As amostras consistem em séries temporais coletadas a 10 Hz durante tarefas de *pick-and-place*, abrangendo tanto o comportamento normal quanto cenários de falhas simuladas, como colisões (base e braço) e variações de carga. Essa diversidade torna o *dataset* ideal para avaliar a eficácia de técnicas de análise exploratória, pré-processamento e aprendizado de máquina na caracterização de falhas industriais.

II. ANÁLISE DE DADOS E FEATURE ENGINEERING

A. Análise Exploratória dos Dados

1) *Análise Exploratória Estrutural*: A análise exploratória estrutural foi conduzida com o objetivo de compreender a organização e os tipos de atributos presentes no conjunto de dados. Para garantir a integridade da avaliação durante as etapas de *feature selection* e modelagem de forma a prevenir a tomada de decisão enviesada e o vazamento de dados, adotou-se uma estratégia de particionamento dos dados a priori. A divisão em subconjuntos de Treino, Validação e Teste foi realizada imediatamente após a coleta. O Conjunto de Validação, composto por 10% dos dados Normais e 50% dos dados de Falha (de cada cenário), foi utilizado para a Análise Exploratória de Dados (EDA) e demais etapas subsequentes.

O dataset é composto por séries temporais de sensores inerciais, contendo variáveis numéricas contínuas associadas às medições de acelerômetro, giroscópio e magnetômetro, nos eixos X, Y e Z; uma coluna temporal que representa o instante de coleta de cada amostra e uma variável indicativa da condição de operação do robô, utilizada como rótulo para diferenciar entre comportamento normal e anômalo. Particularmente, os dados anômalos são separados de acordo com o tipo de falha, sendo elas:

- Hitting Platform, que lida com colisão contra a plataforma;
- Hitting Arm, colisão contra o próprio braço robótico;
- Extra Weight, esforço mecânico dado por peso extra;
- Earthquake, vibração estrutural externa.

Cada observação corresponde a uma leitura dos sensores em um determinado instante de tempo, sendo os dados organizados de forma sequencial. A variável temporal é representada por valores inteiros de alta resolução, indicando

registros em escala de nanossegundos, reforçando o caráter temporal do problema. No entanto, com o objetivo de facilitar a interpretação e a análise de integridade temporal, os valores foram convertidos para milissegundos, mantendo a proporcionalidade entre as amostras e reduzindo a magnitude numérica dos registros.

Durante a análise estrutural, foi identificada a presença de uma coluna textual associada à identificação do sensor, que por apresentar valor constante em todas as observações e não agregar informação discriminativa ao problema de detecção de anomalias, essa variável foi removida do conjunto de dados. Adicionalmente, foi realizada a verificação de duplicidade nos registros temporais, não sendo identificadas amostras com timestamps repetidos, o que indica consistência na indexação temporal das observações.

2) *Informações básicas*: O conjunto de dados normais analisado é composto por 874.937 amostras e 11 atributos após a etapa inicial de pré-processamento. Todas as variáveis de sensores são numéricas contínuas do tipo *float64*, enquanto a variável alvo é representada por valores inteiros binários. O volume total de memória ocupado por esse dataset é de aproximadamente 73 MB.

Por outro lado, o conjunto de dados anômalos é composto por 49.185 amostras com os 11 atributos contínuos numéricos e a variável alvo binária. Com um volume total de memória de aproximadamente 10MB. Adicionalmente, o dataset possui um atributo *scenario* que indica o tipo de falha a qual esse registro é associado, seguindo a proporção destacada na tabela abaixo.

TABLE I
QUANTIDADE DE ANOMALIAS POR TIPO DE FALHA

Cenário	Quantidade	Proporção
Hitting Platform	14.967	0.3043
Hitting Arm	11.924	0.2424
Earthquake	11.409	0.2320
Extra Weight	10.885	0.2213 height

3) *Análise de Duplicatas, Valores Faltantes e Outliers*: A integridade dos dados foi avaliada sob três perspectivas: redundância de registros, continuidade temporal e presença de valores extremos.

a) *Duplicatas e Valores Nulos Explícitos*: Uma varredura inicial no conjunto de dados brutos não identificou linhas duplicadas ou valores nulos (*NaN*) explícitos nas leituras dos sensores, tanto nos dados normais quanto anômalos. O sistema de aquisição registrou continuamente as 9 variáveis do IMU (acelerômetros, giroscópios e magnetômetros) sem falhas de escrita evidentes.

b) *Análise de Continuidade Temporal*: Embora não houvesse *NaNs* no arquivo original, a análise do intervalo entre amostras revelou um problema crítico de integridade temporal. A frequência nominal de coleta, era de 10 Hz (com *Sampling Rate* de 100 ms). No entanto, observou-se um *Jitter* (desvio padrão do intervalo de tempo) relevante de aproximadamente 22 ms, com 429 *Gaps* Temporais significativos variando entre 2 ms e 342 ms, onde essa quantidade de perda de pacotes foi

considerada quando o valor do *Gap* foi maior que 2x a média, sendo categorizada como quebra de continuidade.

Para padronizar a frequência e facilitar o janelamento das séries temporais nas etapas seguintes, foi utilizada a técnica de *Resampling*, impondo uma grade temporal rígida de 100 ms, conforme detalhado na seção de Pré-Processamento dos Dados. Nesse contexto, a irregularidade original foi exposta sob a forma de *Gaps* temporais. No conjunto de dados Normal, o alinhamento gerou cerca de 44.766 lacunas onde não havia dados registrados no timestamp esperado.

c) *Análise de Outliers*: A análise de distribuição, por meio de Boxplots e Histogramas, detectou uma quantidade massiva de *outliers* estatísticos, especialmente nos eixos do acelerômetro. Nos dados de colisão (*Hitting Arm*), a curose do eixo Z atingiu valores extremos (> 100), com picos de aceleração de até 10g, muito superiores à faixa média normal de operação ($\pm 1g$). Entretanto, diferente de problemas de regressão clássicos, onde *outliers* são ruídos a serem removidos, neste projeto eles constituem o próprio sinal de interesse (a falha mecânica).

4) *Análise Univariada*: Para determinar a sensibilidade individual de cada sensor aos diferentes modos de falha, conduziu-se uma análise estatística univariada comparativa entre a distribuição dos dados no estado Normal e em cada cenário de anomalia. O objetivo foi quantificar o poder discriminatório de cada eixo do IMU, buscando compreender como a distribuição de cada sensor se comporta diante da mudança para um estado de falha e validar a seleção de *features* para a modelagem.


A divergência entre as distribuições foi avaliada utilizando duas métricas complementares:

- Teste Kolmogorov-Smirnov (KS-Statistic)
- Razão de Variância (σ^2_{ratio})

As Tabelas e Figuras abaixo resumem os sensores mais críticos identificados para cada cenário.

TABLE II
HITTING PLATFORM

Sensor	KS Statistic	Variance Ratio
accZ	0.721	3.254
magZ	0.292	1.022
accX	0.242	1.032
magY	0.152	1.002




Nas falhas de *Hitting Platform*, o acelerômetro vertical (*accZ*) consolidou-se como o indicador primário de anomalia,

apresentando um KS-Statistic de 0,72 e um aumento de mais de 3 vezes na variância do sinal. Este comportamento reflete a natureza física do evento, um impacto abrupto contra a superfície rígida tende a gerar desacelerações impulsivas de alta magnitude que não alteram significativamente a média global do movimento, mas expandem drasticamente a dispersão dos dados momentâneos.

TABLE III
HITTING ARM


Sensor	KS Statistic	Variance Ratio
accZ	0.740	3.279
magY	0.306	0.993
magZ	0.306	1.088
accX	0.301	1.139



O cenário de *Hitting Arm* exibiu uma assinatura estatística semelhante à colisão na plataforma, com o *accZ* liderando a detectabilidade (KS0,74). Contudo, observou-se uma contaminação cruzada mais acentuada nos eixos laterais e nos magnetômetros (ex: *magY* e *accX* com KS0,30), sugerindo que o choque interno induz vibrações multidirecionais e distorções na orientação magnética momentânea superiores às de um impacto simples.

TABLE IV
EARTHQUAKE

Sensor	KS Statistic	Variance Ratio
accZ	0.491	22.402
magX	0.394	0.937
magY	0.303	0.972
magZ	0.274	0.946




A anomalia de *Earthquake* revelou o caso mais extremo de alteração. Embora o KS-Statistic do *accZ* seja moderado

(0,49), indicando que as médias das distribuições não se afastaram radicalmente, a Razão de Variância atingiu um valor crítico de 22,4. Isso indica que a falha não se manifesta por deslocamento de trajetória, mas pela injeção massiva de ruído de alta frequência no sistema, transformando a distribuição normal em uma curva extremamente achatada e espalhada.

TABLE V
EXTRA WEIGHT

Sensor	KS Statistic	Variance Ratio
accZ	0.752	0.776
magX	0.400	0.927
magY	0.314	0.968
magZ	0.281	0.943




Diferentemente dos cenários de impacto e vibração, a falha por *Extra Weight* apresentou um fenômeno de amortecimento dinâmico. O sensor *accZ* manteve a maior separabilidade estatística (KS0,75), mas a variância do sinal sofreu uma redução. Fisicamente, isso sugere que o esforço adicional para sustentar a carga limitou a liberdade de oscilação natural do braço (efeito de rigidez), criando uma assinatura de falha caracterizada pela tensão e menor dispersão em torno da trajetória nominal, oposta ao comportamento das colisões.

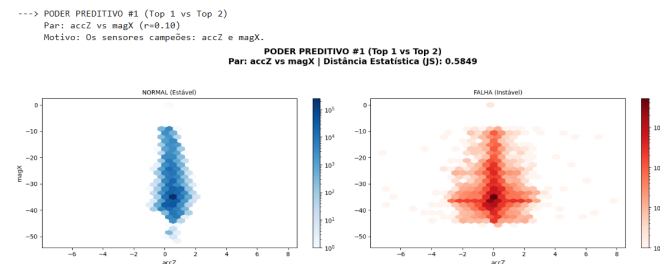
5) *Análise Bivariada*: A análise bivariada partiu da hipótese de que a ocorrência de anomalias afeta o estado físico do robô, questionou-se se as falhas seriam capazes de "quebrar" o acoplamento mecânico entre sensores redundantes ou se as alterações seriam mais perceptíveis em pares de baixa correlação. Para investigar essa premissa, foram definidos cenários analíticos estratégicos, cujo objetivo foi garantir que diferentes tipos de relação entre sensores fossem explicitamente investigados. Essa escolha é importante porque pares de variáveis com comportamentos distintos (alta correlação, correlação média ou baixa correlação) tendem a responder de maneira diferente à introdução de falhas, fornecendo evidências complementares sobre a dinâmica do sistema. A métrica utilizada para quantificar a divergência entre as distribuições do alvo normal e anômalo foi a distância de Jensen-Shannon.

Foram definidos seis cenários bivariados. Nos dois cenários de redundância (pares com maior correlação física), a importância reside em avaliar sensores fortemente acoplados. Nesses casos, observou-se que, mesmo na presença de falhas,


o padrão conjunto se mantém relativamente estável. Quantitativamente, isso se traduziu nas menores distâncias estatísticas observadas: o par (accx, accy) apresentou uma distância JS de apenas 0.12, seguido pelo par (accy, gyroy) com 0.14. Esses baixos valores indicam que falhas nem sempre rompem relações altamente correlacionadas, sugerindo que pares muito redundantes carregam informação similar e tendem a variar de forma conjunta, mesmo em condições anômalas.



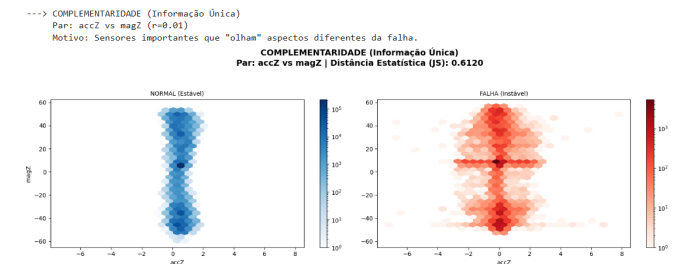
O cenário de linha de base, definido por um par com correlação próxima à média do sistema, foi incluído para representar um comportamento típico. O par (accx, magx) com uma distância JS de 0.20, ilustra essa referência. Esse valor intermediário permite avaliar como a resposta observada em cenários extremos de fato se diferencia do comportamento esperado em uma interação padrão entre sensores.



Já no cenário de complementaridade, composto por sensores pouco correlacionados entre si, observou-se a mudança mais pronunciada entre os dados normais e de falha. A baixa correlação implica que cada sensor responde a aspectos diferentes do fenômeno físico. Quando ocorre uma falha, essas respostas divergentes ampliam drasticamente a separação entre as distribuições conjuntas. Isso ficou evidente nos pares: (accz, magz) atingiu a maior distância registrada (0.61). Esse alto valor confirma que a combinação de variáveis complementares é a mais sensível para capturar a divergência estatística introduzida pelas anomalias.




Por fim, os dois cenários de poder preditivo concentraram-se nos sensores mais correlacionados com o rótulo de falha. A importância desses cenários está em avaliar se sensores individualmente informativos também apresentam mudanças relevantes quando analisados em conjunto. Os resultados indicaram que a introdução de falhas altera a densidade conjunta, embora de forma menos extrema que na complementaridade, ou seja, o que importa não é unicamente a importância do sensor, mas também sua correlação para definir se o par vai se comportar de maneira mais parecida ou não.



Em suma, a análise validou a hipótese inicial: pares altamente correlacionados tendem a mascarar a anomalia, enquanto pares com baixa correlação evidenciam as alterações de forma mais clara.

6) *Análise Multivariada:* Na análise multivariada, todas as variáveis dos sensores foram consideradas simultaneamente por meio do PCA (Principal Component Analysis), após padronização. A projeção nos dois primeiros componentes revelou que as anomalias não são facilmente separáveis dos dados normais. As amostras de falha aparecem cercadas por pontos normais e distribuídas em diferentes regiões do espaço reduzido, indicando que não existe um único padrão geométrico simples que caracterize todas as falhas.

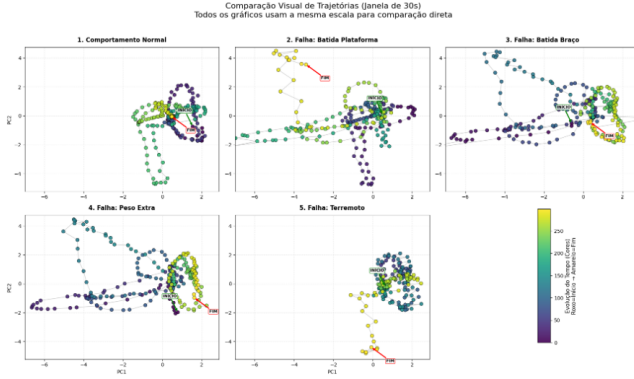


Apesar dessa sobreposição, a visualização evidenciou diferenças estruturais relevantes. Em diversas regiões do espaço PCA, observam-se concentrações de falhas com orientações e dispersões distintas, refletindo o impacto específico de cada tipo de anomalia sobre o sistema. Isso indica que, embora não haja separação linear clara, as falhas alteram a dinâmica multivariada de maneira consistente, produzindo padrões locais diferenciados.

As setas do biplot permitiram interpretar a contribuição de cada sensor para essas diferenças, destacando quais variáveis influenciam mais fortemente determinadas direções do espaço PCA. Sensores com vetores mais extensos tiveram maior peso na organização dos dados, ajudando a explicar por que


determinadas anomalias se manifestam em regiões específicas do plano.

A análise foi complementada pela visualização temporal de janelas de 30 segundos no espaço PCA, utilizando uma régua visual fixa para todos os cenários. Essa abordagem evidenciou que o comportamento normal tende a produzir trajetórias mais compactas e regulares, enquanto os cenários de falha apresentam trajetórias mais dispersas e irregulares, reforçando o impacto dinâmico das anomalias ao longo do tempo.



No que se refere às variáveis derivadas, foram calculadas magnitudes físicas da aceleração, do giroscópio e do magnetômetro, com o objetivo de condensar informações multieixo em medidas escalares fisicamente interpretáveis.

Testes exploratórios básicos, como a comparação de distribuições entre classes e análises de separação estatística, indicaram que essas variáveis capturam alterações relevantes introduzidas pelas falhas, mostrando potencial para uso na otimização dos modelos subsequentes, permitindo, por exemplo, estratégias de redução de dimensionalidade que mantenham a interpretabilidade física do fenômeno ao diminuir o número de variáveis de entrada.



Por fim, aplicou-se o K-Means para identificar grupos de interesse no espaço formado pelas variáveis originais. O uso de um método não supervisionado é adequado nesse contexto, pois permite investigar a estrutura intrínseca dos dados sem recorrer aos rótulos. Os resultados mostraram que, considerando apenas os dados brutos, não foi possível identificar um grupo claramente dominante em termos de concentração de falhas.

Cluster	Normal (%)	Falha (%)
0	96.601872	3.398128
1	96.528435	3.471565
2	96.646539	3.353461

B. Pré-processamento dos dados

Apresentar ações referentes ao pré-processamento de dados a exemplo de:

1) *Tratamento de Valores Faltantes*: Para corrigir os problemas de *timestamps* irregularmente espaçadas e amostras faltantes, sem descartar dados, optou-se pela interpolação linear dos valores faltantes gerados pelo *Resampling*. Essa abordagem preservou a tendência do movimento entre os pontos conhecidos, restaurando a continuidade necessária para a extração de *features* de janela deslizante.

Para os conjuntos de dados anômalos, a etapa de regularização temporal com *Resampling* e Interpolação foi aplicada de forma iterativa e independente para cada cenário de falha, ao invés da aplicação direta sobre o conjunto anômalo completo. Essa abordagem foi necessária para prevenir as descontinuidades temporais, visto que os experimentos de falha foram registrados em contextos diferentes e com *Gaps* de minutos a horas entre si e a imposição de uma grade temporal contínua de 10Hz no dataset completo forçaria a criação de milhares de linhas vazias para preencher esses intervalos e a interpolação linear geraria dados sintéticos falsos, o que tornaria inviável alimentar o modelo com esses dados, mesmo com etapas subsequentes de pré-processamento.

2) *Tratamento de Outliers e Feature Scaling*: Conforme detalhado anteriormente, os *outliers* identificados representam uma parte importante do problema e representam medições verossímeis. Consequentemente, optou-se por não removê-los. No entanto, tendo em mente a fonte dos dados e a natureza dos sensores, foi necessário aplicar um filtro para reduzir o ruído dos sinais, sendo utilizado o Savitzky-Golay, que ajusta polinômios localmente, por sua capacidade de preservar melhor a forma e pico dos sinais que outros baseados em médias rolantes. Adicionalmente, para mitigar o impacto desses valores extremos dos sensores na normalização dos dados, substituiu-se o *StandardScaler* (sensível à média/desvio padrão) pelo *RobustScaler*, sendo este ajustado somente ao conjunto de testes dos dados normais e posteriormente usado para transformar os outros conjuntos. Este escalonador utiliza a mediana e o intervalo interquartil (IQR), garantindo que os picos de colisão permaneçam destacados na escala transformada, preservando a assinatura da anomalia para o modelo.

3) *Deteção e Tratamento de Duplicadas*: Não havia duplicadas no *dataset*, devido ao processo de geração deste [2].

4) *Encoding de Variáveis Categóricas*: Os dados não contém qualquer variável categórica, sendo desnecessárias estratégias de *encoding*.

C. Divisão dos Dados

Justificar e apresentar a divisão de dados entre Treino, Validação e Teste com justificativas a respeito da técnica utilizada.

D. Feature Engineering

Deverá abordar a seleção e extração de *features* caso cabível. Em caso de utilização de técnicas de redução de dimensionalidade, justificar a escolha do método e configurações.

III. MODELAGEM

Nesta seção deverá ser feita uma breve revisão dos algoritmos selecionados. Além disso, justificar a escolha do algoritmo juntamente com hiperparâmetros a serem testados. Importante explicitar qual(is) foi(ram) o(s) espaço(s) de busca utilizado, bem como a técnica escolhida para tunagem de hiperparâmetros.

A. Modelo A

- 1) Conceitos Básicos:
- 2) Justificativa:
- 3) Espaço de Busca:
- 4) Hiperparâmetros Selecionados:

B. Modelo B

- 1) Conceitos Básicos:
- 2) Justificativa:
- 3) Espaço de Busca:
- 4) Hiperparâmetros Selecionados:

C. Modelo C

- 1) Conceitos Básicos:
- 2) Justificativa:
- 3) Espaço de Busca:
- 4) Hiperparâmetros Selecionados:

IV. ANÁLISE E COMPARAÇÃO DE RESULTADOS

Deverá conter as métricas que foram utilizadas para a análise juntamente com revisão de conceito e justificativas. É fundamental comparar os resultados obtidos entre os diferentes modelos treinados. Além disso, é interessante utilizar ferramentas estatísticas e/ou testes de hipótese quando cabível.

V. CONCLUSÃO E DISCUSSÃO

Explicar os principais achados ao longo do trabalho bem como vantagens e limitações de métodos e/ou algoritmos selecionados. Além disso, apresentar principais *insights* extraídos e potenciais trabalhos futuros.

MATERIAL DE APOIO

TABLE VI
EXEMPLO DE TABELA

Trabalhos	Método	Vantagens	Desvantagens
Trabalho A	Método X	A	D
Trabalho B	Método Y	G	J

VI. MODELO DE AMEAÇA (SE APLICÁVEL)

Utilizar figuras e/ou algoritmos e/ou equações para descrever os comportamentos da análise.

Na Eq. (1) é apresentado um exemplo de equação com a equação de uma reta.

$$y = ax + b \quad (1)$$

Na Fig. 1 é apresentado um exemplo de figura com a logo do centro de informática.



Fig. 1. Logo do centro de informática.

No Alg. 1 é apresentado um exemplo de algoritmo.

Algorithm 1 Algoritmo com legenda

Require: $n \geq 0$

Ensure: $y = x^n$

$y \leftarrow 1$

$X \leftarrow x$

$N \leftarrow n$

while $N \neq 0$ **do**

if N is even **then**

$X \leftarrow X \times X$

$N \leftarrow \frac{N}{2}$

▷ Exemplo de comentário

else if N is odd **then**

$y \leftarrow y \times X$

$N \leftarrow N - 1$

end if

end while

REFERÊNCIAS

- [1] H. Kayan, R. Heartfield, O. Rana, P. Burnap, and C. Perera, “CASPER: Context-Aware IoT Anomaly Detection System for Industrial Robotic Arms,” *ACM Transactions on Internet of Things*, vol. 5, no. 3, art. 18, Aug. 2024, doi: 10.1145/3670414.
- [2] H. Kayan, R. Heartfield, O. Rana, P. Burnap, and C. Perera, “Real-Time Anomaly Detection for Industrial Robotic Arms Using Edge Computing,” *2023 IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)*, 2023.
- [3] A. Blázquez-García, M. S. Del Aguila, I. López, P. López, and F. Sánchez, “A review on outlier/anomaly detection in time series data,” *ACM Computing Surveys*, vol. 54, no. 3, pp. 1–33, 2021.
- [4] M. S. R. Silva, J. A. Pereira, and P. S. Neto, “Anomaly Detection Methods in Autonomous Robotic Missions,” *Sensors (MDPI)*, vol. 24, no. 4, art. 1330, 2024.
- [5] M. A. Zheng, L. X. Wang, T. J. Hu, “Unsupervised Anomaly Detection for Autonomous Robots via Mahalanobis SVDD with Audio-IMU Fusion,” *arXiv preprint arXiv:2505.05811*, 2025.