

# Detecção de Anomalias em Robôs Industriais

1<sup>st</sup> Andre Saghard

*Centro de Informática - UFPE*

Recife, Brazil

afs15@cin.ufpe.br

2<sup>nd</sup> Bianca Paes

*Centro de Informática - UFPE*

Recife, Brazil

bpas@cin.ufpe.br

3<sup>rd</sup> Caio Nascimento

*Centro de Informática - UFPE*

Recife, Brazil

cns@cin.ufpe.br

4<sup>rd</sup> Rodrigo Gomes

*Centro de Informática - UFPE*

Recife, Brazil

rgar@cin.ufpe.br

**Abstract—**Breve apresentação do contexto do trabalho, problema/tema a ser abordado, soluções existentes, método proposto e resultados obtidos.

## I. INTRODUÇÃO

A motivação para este estudo decorre da crescente adoção de robôs industriais em operações críticas, onde a execução de tarefas repetitivas em proximidade com operadores exige monitoramento constante. Neste contexto, a identificação automática de anomalias é essencial para detectar falhas mecânicas e interferências externas, garantindo a integridade do equipamento e a segurança do processo.

A análise baseia-se em dados de sensores iniciais (IMU), capazes de capturar a dinâmica do manipulador. O acelerômetro monitora vibrações e impactos abruptos (indicativos de colisões), enquanto o giroscópio registra a velocidade angular, permitindo identificar oscilações ou atrasos causados por cargas excessivas. O magnetômetro, mede a orientação do sistema em relação ao campo magnético terrestre, apresentando variações mais lentas e sendo sensível a interferências magnéticas inesperadas. Como o robô opera em ciclos sequenciais, os sinais normais apresentam periodicidade bem definida; desvios nesse padrão, como alterações de forma de onda ou picos de energia, constituem as assinaturas principais de condições anômalas.

O conjunto de dados utilizado provém de experimentos públicos (IEEE PerCom 2023) realizados com um braço robótico UR3e em ambiente controlado. As amostras consistem em séries temporais coletadas a 10 Hz durante tarefas de *pick-and-place*, abrangendo tanto o comportamento normal quanto cenários de falhas simuladas, como colisões (base e braço) e variações de carga. Essa diversidade torna o dataset ideal para avaliar a eficácia de técnicas de análise exploratória, pré-processamento e aprendizado de máquina na caracterização de falhas industriais.

## II. ANÁLISE DE DADOS E FEATURE ENGINEERING

### A. Análise Exploratória dos Dados

1) *Análise Exploratória Estrutural:* A análise exploratória estrutural foi conduzida com o objetivo de compreender a organização e os tipos de atributos presentes no conjunto de

dados. Para garantir a integridade da avaliação durante as etapas de *feature selection* e modelagem de forma a prevenir a tomada de decisão enviesada e o vazamento de dados, adotou-se uma estratégia de particionamento dos dados a priori. A divisão em subconjuntos de Treino, Validação e Teste foi realizada imediatamente após a coleta. O Conjunto de Validação, composto por 10% dos dados Normais e 50% dos dados de Falha (de cada cenário), foi utilizado para a Análise Exploratória de Dados (EDA) e demais etapas subsequentes.

O dataset é composto por séries temporais de sensores iniciais, contendo variáveis numéricas contínuas associadas às medições de acelerômetro, giroscópio e magnetômetro, nos eixos X, Y e Z; uma coluna temporal que representa o instante de coleta de cada amostra e uma variável indicativa da condição de operação do robô, utilizada como rótulo para diferenciar entre comportamento normal e anômalo. Particularmente, os dados anômalos são separados de acordo com o tipo de falha, sendo elas:

- Hitting Platform, que lida com colisão contra a plataforma;
- Hitting Arm, colisão contra o próprio braço robótico;
- Extra Weight, esforço mecânico dado por peso extra;
- Earthquake, vibração estrutural externa.

Cada observação corresponde a uma leitura dos sensores em um determinado instante de tempo, sendo os dados organizados de forma sequencial. A variável temporal é representada por valores inteiros de alta resolução, indicando registros em escala de nanosegundos, reforçando o caráter temporal do problema. No entanto, com o objetivo de facilitar a interpretação e a análise de integridade temporal, os valores foram convertidos para milissegundos, mantendo a proporcionalidade entre as amostras e reduzindo a magnitude numérica dos registros.

Durante a análise estrutural, foi identificada a presença de uma coluna textual associada à identificação do sensor, que por apresentar valor constante em todas as observações e não agregar informação discriminativa ao problema de detecção de anomalias, essa variável foi removida do conjunto de dados. Adicionalmente, foi realizada a verificação de duplicidade nos registros temporais, não sendo identificadas amostras com

timestamps repetidos, o que indica consistência na indexação temporal das observações.

2) *Informações básicas:* O conjunto de dados normais analisado é composto por 874.937 amostras e 11 atributos após a etapa inicial de pré-processamento. Todas as variáveis de sensores são numéricas contínuas do tipo *float64*, enquanto a variável alvo é representada por valores inteiros binários. O volume total de memória ocupado por esse dataset é de aproximadamente 73 MB.

Por outro lado, o conjunto de dados anômalos é composto por 49.185 amostras com os 11 atributos contínuos numéricos e a variável alvo binária. Com um volume total de memória de aproximadamente 10MB. Adicionalmente, o dataset possui um atributo *scenario* que indica o tipo de falha a qual esse registro é associado, seguindo a proporção destacada na tabela abaixo.

TABLE I  
QUANTIDADE DE ANOMALIAS POR TIPO DE FALHA

Cenário	Quantidade	Proporção
Hitting Platform	14.967	0.3043
Hitting Arm	11.924	0.2424
Earthquake	11.409	0.2320
Extra Weight	10.885	0.2213

3) *Análise de Duplicatas, Valores Faltantes e Outliers:* A integridade dos dados foi avaliada sob três perspectivas: redundância de registros, continuidade temporal e presença de valores extremos.

a) *Duplicatas e Valores Nulos Explícitos:* Uma varredura inicial no conjunto de dados brutos não identificou linhas duplicadas ou valores nulos (*NaN*) explícitos nas leituras dos sensores, tanto nos dados normais quanto anômalos. O sistema de aquisição registrou continuamente as 9 variáveis do IMU (acelerômetros, giroscópios e magnetômetros) sem falhas de escrita evidentes.

b) *Análise de Continuidade Temporal:* Embora não houvesse *Nan*s no arquivo original, a análise do intervalo entre amostras revelou um problema crítico de integridade temporal. A frequência nominal de coleta, era de 10 Hz (com *Sampling Rate* de 100 ms). No entanto, observou-se um *Jitter* (desvio padrão do intervalo de tempo) relevante de aproximadamente 22 ms, com 429 *Gaps* Temporais significativos variando entre 2 ms e 342 ms, onde essa quantidade de perda de pacotes foi considerada quando o valor do *Gap* foi maior que 2x a média, sendo categorizada como quebra de continuidade.

Para padronizar a frequência e facilitar o janelamento das séries temporais nas etapas seguintes, foi utilizada a técnica de *Resampling*, impondo uma grade temporal rígida de 100 ms, conforme detalhado na seção de Pré-Processamento dos Dados. Nesse contexto, a irregularidade original foi exposta sob a forma de *Gaps* temporais. No conjunto de dados Normal, o alinhamento gerou cerca de 44.766 lacunas onde não havia dados registrados no timestamp esperado.

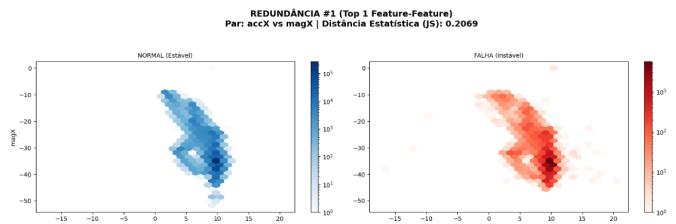
c) *Análise de Outliers:* A análise de distribuição, por meio de Boxplots e Histogramas, detectou uma quantidade massiva de *outliers* estatísticos, especialmente nos eixos do acelerômetro. Nos dados de colisão (*Hitting Arm*), a curtose

do eixo Z atingiu valores extremos ( $> 100$ ), com picos de aceleração de até 10g, muito superiores à faixa média normal de operação ( $\pm 1g$ ). Entretenato, diferente de problemas de regressão clássicos, onde *outliers* são ruídos a serem removidos, neste projeto eles constituem o próprio **sinal de interesse** (a falha mecânica).

4) *Análise Univariada:* Executar análises entre atributos e alvo de forma univariada com descrição estatística e visualizações de apoio.

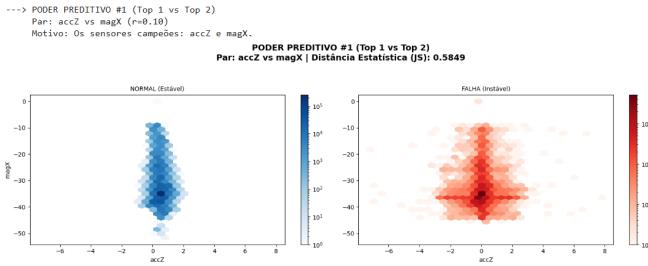
5) *Análise Bivariada:* A análise bivariada partiu da hipótese de que a ocorrência de anomalias afeta o estado físico do robô, questionou-se se as falhas seriam capazes de "quebrar" o acoplamento mecânico entre sensores redundantes ou se as alterações seriam mais perceptíveis em pares de baixa correlação. Para investigar essa premissa, foram definidos cenários analíticos estratégicos, cujo objetivo foi garantir que diferentes tipos de relação entre sensores fossem explicitamente investigados. Essa escolha é importante porque pares de variáveis com comportamentos distintos (alta correlação, correlação média ou baixa correlação) tendem a responder de maneira diferente à introdução de falhas, fornecendo evidências complementares sobre a dinâmica do sistema. A métrica utilizada para quantificar a divergência entre as distribuições do alvo normal e anômalo foi a distância de Jensen-Shannon.

Foram definidos seis cenários bivariados. Nos dois cenários de redundância (pares com maior correlação física), a importância reside em avaliar sensores fortemente acoplados. Nesses casos, observou-se que, mesmo na presença de falhas, o padrão conjunto se mantém relativamente estável. Quantitativamente, isso se traduziu nas menores distâncias estatísticas observadas: o par (accx,accy) apresentou uma distância JS de apenas 0.12, seguido pelo par (accy,gyro) com 0.14. Esses baixos valores indicam que falhas nem sempre rompem relações altamente correlacionadas, sugerindo que pares muito redundantes carregam informação similar e tendem a variar de forma conjunta, mesmo em condições anômalas.

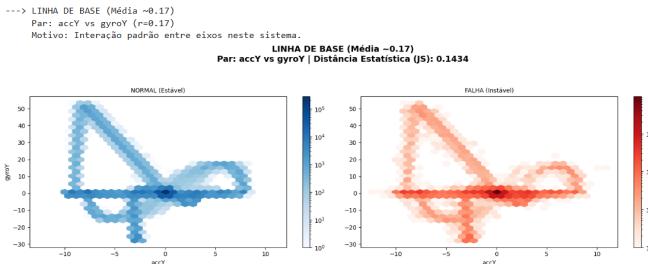


O cenário de linha de base, definido por um par com correlação próxima à média do sistema, foi incluído para representar um comportamento típico. O par (accx,magx) com uma distância JS de 0.20, ilustra essa referência. Esse valor intermediário permite avaliar como a resposta observada em cenários extremos de fato se diferencia do comportamento esperado em uma interação padrão entre sensores.

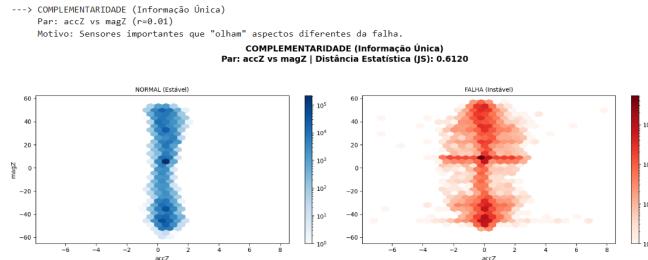
Já no cenário de complementaridade, composto por sensores pouco correlacionados entre si, observou-se a mudança mais pronunciada entre os dados normais e de falha. A



baixa correlação implica que cada sensor responde a aspectos diferentes do fenômeno físico. Quando ocorre uma falha, essas respostas divergentes ampliam drasticamente a separação entre as distribuições conjuntas. Isso ficou evidente nos pares: (accz,magz) atingiu a maior distância registrada (0.61). Esse alto valor confirma que a combinação de variáveis complementares é a mais sensível para capturar a divergência estatística introduzida pelas anomalias.



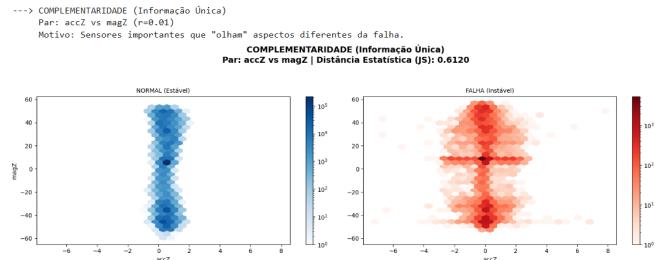
Por fim, os dois cenários de poder preditivo concentraram-se nos sensores mais correlacionados com o rótulo de falha. A importância desses cenários está em avaliar se sensores individualmente informativos também apresentam mudanças relevantes quando analisados em conjunto. Os resultados indicaram que a introdução de falhas altera a densidade conjunta, embora de forma menos extrema que na complementaridade, ou seja, o que importa não é unicamente a importância do sensor, mas também sua correlação para definir se o par vai se comportar de maneira mais parecida ou não.



Em suma, a análise validou a hipótese inicial: pares altamente correlacionados tendem a mascarar a anomalia, enquanto pares com baixa correlação evidenciam as alterações de forma mais clara.

6) Análise Multivariada: Na análise multivariada, todas as variáveis dos sensores foram consideradas simultaneamente por meio do PCA (Principal Component Analysis), após

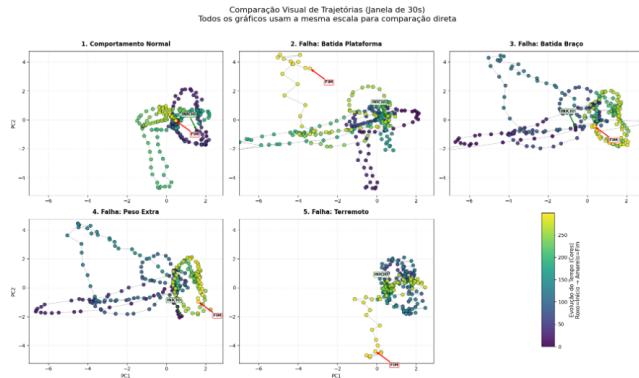
padronização. A projeção nos dois primeiros componentes revelou que as anomalias não são facilmente separáveis dos dados normais. As amostras de falha aparecem cercadas por pontos normais e distribuídas em diferentes regiões do espaço reduzido, indicando que não existe um único padrão geométrico simples que caracterize todas as falhas.



Apesar dessa sobreposição, a visualização evidenciou diferenças estruturais relevantes. Em diversas regiões do espaço PCA, observam-se concentrações de falhas com orientações e dispersões distintas, refletindo o impacto específico de cada tipo de anomalia sobre o sistema. Isso indica que, embora não haja separação linear clara, as falhas alteram a dinâmica multivariada de maneira consistente, produzindo padrões locais diferenciados.

As setas do biplot permitiram interpretar a contribuição de cada sensor para essas diferenças, destacando quais variáveis influenciam mais fortemente determinadas direções do espaço PCA. Sensores com vetores mais extensos tiveram maior peso na organização dos dados, ajudando a explicar por que determinadas anomalias se manifestam em regiões específicas do plano.

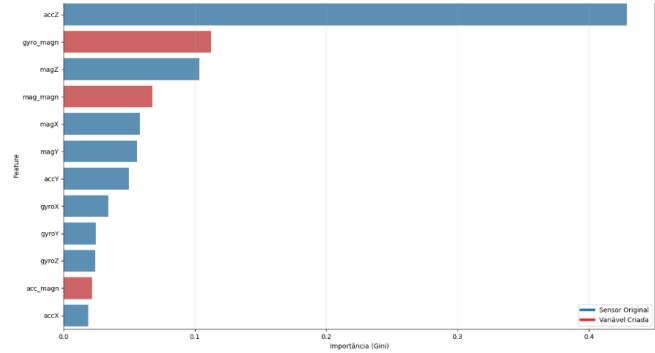
A análise foi complementada pela visualização temporal de janelas de 30 segundos no espaço PCA, utilizando uma régua visual fixa para todos os cenários. Essa abordagem evidenciou que o comportamento normal tende a produzir trajetórias mais compactas e regulares, enquanto os cenários de falha apresentam trajetórias mais dispersas e irregulares, reforçando o impacto dinâmico das anomalias ao longo do tempo.



No que se refere às variáveis derivadas, foram calculadas magnitudes físicas da aceleração, do giroscópio e do mag-

netômetro, com o objetivo de condensar informações multieixo em medidas escalares fisicamente interpretáveis.

Testes exploratórios básicos, como a comparação de distribuições entre classes e análises de separação estatística, indicaram que essas variáveis capturam alterações relevantes introduzidas pelas falhas, mostrando potencial para uso na otimização dos modelos subsequentes, permitindo, por exemplo, estratégias de redução de dimensionalidade que mantenham a interpretabilidade física do fenômeno ao diminuir o número de variáveis de entrada.



Por fim, aplicou-se o K-Means para identificar grupos de interesse no espaço formado pelas variáveis originais. O uso de um método não supervisionado é adequado nesse contexto, pois permite investigar a estrutura intrínseca dos dados sem recorrer aos rótulos. Os resultados mostraram que, considerando apenas os dados brutos, não foi possível identificar um grupo claramente dominante em termos de concentração de falhas.

Cluster	Normal (%)	Falha (%)
0	96.601872	3.398128
1	96.528435	3.471565
2	96.646539	3.353461

### B. Pré-processamento dos dados

Apresentar ações referentes ao pré-processamento de dados a exemplo de:

1) *Tratamento de Valores Faltantes*: Para corrigir os problemas de *timestamps* irregularmente espaçadas e amostras faltantes, sem descartar dados, optou-se pela **interpolação linear** dos valores faltantes gerados pelo *Resampling*. Essa abordagem preservou a tendência do movimento entre os pontos conhecidos, restaurando a continuidade necessária para a extração de *features* de janela deslizante.

Para os conjuntos de dados anômalos, a etapa de regularização temporal com *Resampling* e Interpolação foi aplicada de forma iterativa e independente para cada cenário de falha, ao invés da aplicação direta sobre o conjunto anômalo completo. Essa abordagem foi necessária para prevenir as descontinuidades temporais, visto que os experimentos de falha foram registrados em contextos diferentes e com *Gaps* de minutos a horas entre si e a imposição de uma grade temporal contínua de 10Hz no dataset completo forçaria a criação de milhares de linhas vazias para preencher esses intervalos e

a interpolação linear geraria dados sintéticos falsos, o que tornaria inviável alimentar o modelo com esses dados, mesmo com etapas subsequentes de pré-processamento.

2) *Tratamento de Outliers e Feature Scaling*: Conforme detalhado anteriormente, os *outliers* identificados representam uma parte importante do problema e representam medições verossímeis. Consequentemente, optou-se por **não removê-los**. No entanto, tendo em mente a fonte dos dados e a natureza dos sensores, foi necessário aplicar um filtro para reduzir o ruído dos sinais, sendo utilizado o Savitzky-Golay, que ajusta polinômios localmente, por sua capacidade de preservar melhor a forma e pico dos sinais que outros baseados em médias rolantes. Adicionalmente, para mitigar o impacto desses valores extremos dos sensores na normalização dos dados, substituiu-se o *StandardScaler* (sensível à média/desvio padrão) pelo **RobustScaler**, sendo este ajustado somente ao conjunto de testes dos dados normais e posteriormente usado para transformar os outros conjuntos. Este escalonador utiliza a mediana e o intervalo interquartil (IQR), garantindo que os picos de colisão permaneçam destacados na escala transformada, preservando a assinatura da anomalia para o modelo.

3) *Detecção e Tratamento de Duplicadas*: Não havia duplicadas no *dataset*, devido ao processo de geração deste [?].

4) *Encoding de Variáveis Categóricas*: Os dados não contém qualquer variável categórica, sendo desnecessárias estratégias de *encoding*.

### C. Divisão dos Dados

Os dados normais, não-anomais, conforme ilustrado em ??, foram divididos em 60%, 20% e 20% entre os conjuntos de treinamento, validação e teste, respectivamente, enquanto foi dividido em 50% para a validação e 50% para o conjunto de testes. Em ambos os casos, a divisão respeitou a ordenação dos dados ao longo do tempo, visando evitar o vazamento de informações e a violação das relações temporais entre os pontos de dados.

Além disso, no caso dos dados anômalos, foi feita divisão estratificada, para garantir que cada classe de anomalia, que ocorreram cada uma independentemente e não concomitantemente, como os choques na plataforma e os choques no braço robótico, estivessem proporcionalmente representadas nos conjuntos de validação e teste.

TABLE II  
DIVISÃO PERCENTUAL DOS CONJUNTOS DE DADOS

Conjunto de Dados	Treino (%)	Validação (%)	Teste (%)
Normal	60,0	20,0	20,0
Anomalia	0,0	50,0	50,0

### D. Feature Engineering

A estratégia de engenharia de atributos (*Feature Engineering*) adotada neste trabalho foi adaptada aos diferentes tipos de modelos avaliados. Processo de extração manual de atributos foi aplicado **exclusivamente** aos modelos probabilísticos e baseados em densidade (Isolation Forest, Gaussian Mixture Models).

Para as abordagens baseadas em Deep Learning, foram usados os dados brutos das séries temporais, submetidos apenas à criação de janelas, considerando a capacidade dessas arquiteturas de fazer (*representation learning*) e capturar dependências temporais complexas. Em contrapartida, os modelos clássicos carecem da habilidade nativa de interpretar a sequencialidade temporal de alta dimensão dos sensores brutos (90 dimensões por segundo de janela) tornando imperativa a transformação desses dados em vetores de estatísticas descritivas que sintetizem o comportamento dinâmico e espectral do robô.

Dessa forma, o *pipeline* de engenharia de atributos para os modelos clássicos foi feito em três etapas: Criação de janelas, extração e seleção, conforme detalhado a seguir.

1) *Criação de janelas*: Para a criação de janelas, foram utilizadas janelas móveis (*sliding windows*)??, que possuem uma intercessão ajustável com as janelas imediatamente vizinhas. Um algoritmo ilustrativo para a criação de janelas deslizantes é descrito em ??.

Cada parte dos dados passou por esse processo isoladamente, e janelas incompletas foram descartadas para garantir a uniformidade das matrizes resultantes. Por exemplo, visto que a frequência de coleta de dados foi de 10Hz, uma janela de 40 amostras captura 4 segundos de funcionamento do braço robótico. Ademais, os parâmetros das janelas foram considerados como hiperparâmetros na etapa da modelagem, para que sejam escolhidos otimamente. Esta escolha é muito importante, porque o tamanho da janela depende muito dos modelos, e os eventos de interesse são muitos particulares do problema. No caso desse dataset, observamos que os eventos de interesse de fato exigiam uma análise um período de alguns segundos.

---

#### **Algorithm 1** Segmentação em Janelas Deslizantes (Sliding Windows)

**Require:**  $D$  (Dados  $N \times F$ ),  $L$  (Tamanho da Janela),  $O$  (Overlap)  
**Ensure:**  $\mathcal{W}$  (Tensor de janelas  $M \times L \times F$ )

```

 $S \leftarrow L - O$ 
 $N \leftarrow \text{rows}(D)$ 
 $\mathcal{W} \leftarrow \emptyset$ 
 $i \leftarrow 0$ 
while  $i + L \leq N$  do
     $w \leftarrow D[i : i + L, :]$ 
     $\mathcal{W} \leftarrow \mathcal{W} \cup \{w\}$ 
     $i \leftarrow i + S$ 
end while
return  $\mathcal{W}$ 
```

---

2) *Extração e seleção de features*: Nesta etapa, buscamos transformar os sinais dos sensores em uma representação mais informativa, bem como adaptá-la às limitações dos modelos que não usam Deep Learning usados neste trabalho, que não lidam bem com a grande quantidade de dimensões envolvida e com a alta correlação entre features. Esse processo se dividiu entre a extração e a seleção de features.

Inicialmente, fizemos a extração de features a nível de amostra. A partir dos sinais originais, criamos variáveis derivadas utilizando a interpretação física do problema e do que cada variável representava, como a norma vetorial de cada sensor, que captura a magnitude total da mudança por ele registrada, unindo os eixos.

Em seguida, os sinais e seus atributos derivados foram segmentados em janelas como descrito acima. Para cada janela, foram extraídas estatísticas agregadas calculadas exclusivamente com as *features* originais, agregando tendências e informações sobre o período inteiro de tempo representado pelo tamanho da janela.

- 1) **Média**: representa o valor médio do sinal ao longo da janela e está associada ao nível basal ou tendência local do movimento. Alterações na média podem indicar mudanças sistemáticas no comportamento do sistema, como inclinações persistentes ou deslocamentos contínuos.
- 2) **Desvio padrão**: quantifica a variabilidade do sinal dentro da janela, sendo fortemente associado à intensidade de vibrações.
- 3) **RMS (Root Mean Square)**: mede a energia total do sinal, combinando informações de magnitude e variabilidade. Diferentemente da média, o RMS é sensível tanto a oscilações quanto a impactos.
- 4) **Pico-a-pico (peak-to-peak)**: corresponde à diferença entre os valores máximo e mínimo do sinal na janela, também capturando grandes variações.
- 5) **Curtose**: caracteriza o grau de impulsividade do sinal, indicando a presença de picos abruptos e eventos raros de grande magnitude..
- 6) **Fator de crista (crest factor)**: definido como a razão entre o valor de pico e o RMS, fornece uma medida normalizada da severidade dos picos em relação à energia média do sinal. Essa *feature* é especialmente útil para diferenciar vibrações contínuas de impactos pontuais.
- 7) **Frequência dominante**: extraída a partir da transformada de Fourier da janela, indica a frequência com maior energia espectral. Essa informação permite capturar características dinâmicas do sistema, como ressonâncias, mudanças de regime de operação ou vibrações induzidas por cargas externas.

Essas *features* sintetizam muitas propriedades fundamentais do comportamento do sinal dentro da janela e constituem uma representação comparativamente compacta desse comportamento. Dessa forma, ao invés de termos um total de  $features * \text{tamanhoDaJanela}$  dimensões, ou seja, 360, no caso dos nossos 9 sensores e uma janela de 40 amostras, obtemos apenas 72 dimensões.

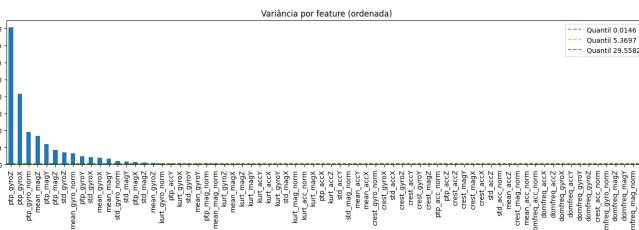
o entanto, apesar de representar uma redução considerável da dimensionalidade, essas *features* ainda podem apresentar elevada redundância estatística. Em particular, muitas das estatísticas extraídas descrevem aspectos relacionados do sinal (por exemplo, desvio padrão, RMS e pico-a-pico), o que resulta em fortes correlações lineares entre atributos. A presença

desse tipo de redundância pode prejudicar o desempenho de modelos probabilísticos e baseados em densidade, além de aumentar o custo computacional e dificultar a interpretação dos resultados.

Dessa forma, foi aplicada uma etapa explícita de seleção de *features*. Inicialmente, realizou-se uma análise de correlação linear entre os atributos extraídos, utilizando o coeficiente de correlação de Pearson. Para cada par de *features* cuja correlação absoluta excedia um limiar de 0,95, apenas uma delas foi mantida. Essa estratégia visa eliminar atributos altamente redundantes, preservando, ao mesmo tempo, a maior diversidade possível de informações relevantes. Após essa etapa, o número de *features* foi reduzido de 72 para 58.

Mesmo após a remoção de correlações elevadas, o espaço de atributos ainda permanecia relativamente grande e com possíveis dependências lineares de ordem superior. Assim, aplicou-se uma etapa adicional de redução de dimensionalidade por meio da Análise de Componentes Principais (PCA). O PCA foi ajustado exclusivamente sobre o conjunto de treinamento, após normalização robusta dos dados, e o número de componentes foi selecionado de forma a preservar pelo menos 95% da variância total dos dados. Como resultado, o espaço de atributos foi reduzido de 58 para 15 componentes principais, mantendo uma variância explicada acumulada de aproximadamente 95,28.

Essa combinação de seleção por correlação e redução via PCA permitiu obter uma representação compacta, pouco redundante e estatisticamente bem condicionada dos dados, adequada às premissas dos modelos clássicos avaliados neste trabalho. Além disso, ao concentrar a maior parte da variabilidade dos sinais em um número reduzido de componentes, essa abordagem contribui para maior estabilidade numérica, melhor generalização e menor sensibilidade a ruído.



### III. MODELAGEM

Nesta seção deverá ser feita uma breve revisão dos algoritmos selecionados. Além disso, justificar a escolha do algoritmo juntamente com hiperparâmetros a serem testados. Importante explicitar qual(is) foi(ram) o(s) espaço(s) de busca utilizado, bem como a técnica escolhida para tunagem de hiperparâmetros.

#### A. Modelo A

- 1) Conceitos Básicos:
- 2) Justificativa:
- 3) Espaço de Busca:
- 4) Hiperparâmetros Selecionados:

#### B. Modelo B

- 1) Conceitos Básicos:
- 2) Justificativa:
- 3) Espaço de Busca:
- 4) Hiperparâmetros Selecionados:

#### C. Modelo C

- 1) Conceitos Básicos:
- 2) Justificativa:
- 3) Espaço de Busca:
- 4) Hiperparâmetros Selecionados:

## IV. ANÁLISE E COMPARAÇÃO DE RESULTADOS

Deverá conter as métricas que foram utilizadas para a análise juntamente com revisão de conceito e justificativas. É fundamental comparar os resultados obtidos entre os diferentes modelos treinados. Além disso, é interessante utilizar ferramentas estatísticas e/ou testes de hipótese quando cabível.

## V. CONCLUSÃO E DISCUSSÃO

Explicar os principais achados ao longo do trabalho bem como vantagens e limitações de métodos e/ou algoritmos selecionados. Além disso, apresentar principais *insights* extraídos e potenciais trabalhos futuros.

## REFERÊNCIAS

- [1] H. Kayan, R. Heartfield, O. Rana, P. Burnap, and C. Perera, “CASPER: Context-Aware IoT Anomaly Detection System for Industrial Robotic Arms,” *ACM Transactions on Internet of Things*, vol. 5, no. 3, art. 18, Aug. 2024, doi: 10.1145/3670414.
- [2] H. Kayan, R. Heartfield, O. Rana, P. Burnap, and C. Perera, “Real-Time Anomaly Detection for Industrial Robotic Arms Using Edge Computing,” *2023 IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)*, 2023.
- [3] A. Blázquez-García, M. S. Del Aguila, I. López, P. López, and F. Sánchez, “A review on outlier/anomaly detection in time series data,” *ACM Computing Surveys*, vol. 54, no. 3, pp. 1–33, 2021.
- [4] Y. Yang et al., “Unsupervised Anomaly Detection for Autonomous Robots via Mahalanobis SVDD with Audio-IMU Fusion,” *arXiv preprint arXiv:2505.05811*, 2025.
- [5] S. Chirayil Nandakumar et al., “Anomaly detection methods in autonomous robotic missions,” *Sensors*, vol. 24, no. 4, p. 1330, 2024.
- [6] Keogh, E., Lin, J. Clustering of time-series subsequences is meaningless: implications for previous and future research. *Knowl Inf Syst* 8, 154–177 (2005).